

基于知识蒸馏的跨功率故障诊断防遗忘迁移学习方法

PHM 会议论文草稿 (中文版, 可继续改写为会议模板)

摘要

工业设备在不同功率工况下运行时, 振动信号的幅值、频率分布和冲击模式会发生系统性变化, 导致单一工况训练的故障诊断模型在新功率域上性能显著下降。迁移学习和域适应方法能够利用源域故障知识改善目标域诊断性能, 但标准微调容易产生灾难性遗忘, 即模型在适应目标域的同时快速丧失源域识别能力。针对这一问题, 本文提出一种面向跨功率轴承故障诊断的防遗忘迁移学习框架。该框架以时域振动信号和频域谱图为输入, 构建双流 CrossViT 特征融合网络; 首先在 1.0 kW 源域上预训练教师模型, 然后在 3.0 kW 目标域上进行学生模型适应, 并引入知识蒸馏与 Learning without Forgetting (LWF) 回放约束以保持源域知识。为系统评估不同迁移策略, 本文进一步比较 EWC、DANN、MMD 和伪标签等方法, 并提出同时考虑源域保留率与目标域准确率的 Balance Score。实验结果表明, 知识蒸馏在 $T=1.8$ 、 $\alpha=0.3$ 时取得最佳综合表现, 源域保留率为 60.0%, 目标域准确率为 70.0%, 平衡分达到 80.0; 相比普通微调, 显著缓解了源域遗忘。

关键词: 预测与健康管理; 故障诊断; 跨域迁移; 灾难性遗忘; 知识蒸馏; 持续学习

1 引言

故障预测与健康管理 (PHM) 的目标是在设备发生严重失效之前识别早期异常、评估健康状态并支撑维护决策。旋转机械中的轴承是典型关键部件, 其振动信号包含丰富的冲击、调制和频带信息, 因此深度学习故障诊断模型被广泛用于端到端状态识别。传统卷积网络、残差网络和 Transformer 结构能够从原始信号或时频图中自动学习判别特征, 避免了完全依赖人工特征的局限。

然而, 传统深度学习方法通常隐含一个重要假设: 训练数据和测试数据服从相同或相近分布。在实际 PHM 场景中, 设备会经历功率、载荷、转速、环境和传感器安装状态变化, 导致源域和目标域的边缘分布与条件分布发生偏移。以跨功率轴承故障诊断为例, 在 1.0 kW 工况下训练得到的模型直接用于 3.0 kW 工况时, 目标域准确率会大幅下降, 说明仅依赖单域监督学习难以满足工业部署要求。

迁移学习为上述问题提供了自然思路: 利用源域充足标注数据训练初始模型, 再通过目标域少量标注或无标签数据完成适应。已有工作通常采用特征分布对齐、对抗训练、伪标签学习或多模态特征融合来降低域差异。例如, MMD 类方法通过最小化源域和目标域特征均值嵌入差异进行统计对齐; DANN 类方法通过域判别器和梯度反转层学习域不变表示; 双域信号融合和自注意力网络则进一步增强局部—全局特征表达能力。

但对工业设备而言, 目标域性能并不是唯一目标。设备在全生命周期中可能在多个功率工况之间切换, 旧工况模型能力仍然具有实际价值。普通微调虽然能够提升目标域性能, 却可能导致源域性能急剧下降, 即灾难性遗忘。持续学习领域提出的知识蒸馏、EWC 和数据回放等策略可以缓解遗忘, 但这些策略在跨功率故障诊断迁移中的适用性仍缺乏系统比较。

本文“ 源域保留 ”和“ 目标域迁移 ”目展究, 主要如下: (1) 提出一个基于双流 CrossViT 和知识蒸馏的跨功率故障诊断防遗忘迁移框架; (2) 将知识蒸馏、LWF、EWC、DANN、MMD 和伪标签置于同一实验框架下比较, 揭示其在目标域适应和源域保留之间的权衡; (3) 提出 Balance Score 作为双目标评价指标, 并通过混淆矩阵、训练曲线和注意力激活图解释模型行为。

2 相关工作与方法背景

2.1 传统深度学习故障诊断

传统数据驱动 PHM 方法通常包括数据采集、特征提取、模型训练和性能评价。深度学习相较传统机器学习的优势在于能够直接从原始信号或时频图中学习多层次表示。CNN 擅长提取局部冲击和频带模式，ResNet 缓解深层网络退化问题，Transformer 和自注意力机制能够建模长距离依赖和全局关联。对于轴承信号，时域分支保留冲击周期和幅值变化，频域或时频分支强调故障特征频率及其能量分布，两者结合可以提升复杂工况下的可分性。

2.2 迁移学习与域适应

设源域 $D_s = \{(x_i^s, y_i^s)\}$ ，目标域 $D_t = \{(x_j^t, y_j^t)\}$ 或无标签目标域 $D_u^t = \{x_j^t\}$ 。当 $P_s(x, y) \neq P_t(x, y)$ 时，源域模型 h_s 在目标域上会出现泛化下降。域适应的核心是学习特征提取器 f ，使 $f(x^s)$ 和 $f(x^t)$ 在特征空间中尽可能对齐，同时保持故障类别判别能力。MMD 和 MK-MMD 通过核均值嵌入衡量分布差异，DANN 通过域判别器的对抗训练学习域不变特征，伪标签方法则利用目标域高置信预测扩充监督信号。

$$L_{DA} = L_{cls} + \lambda_{mmd} * MMD(f(X_s), f(X_t)) + \lambda_{adv} * L_{adv}$$

2.3 持续学习与知识蒸馏

持续学习关注模型在学习新任务或新域时如何保留旧知识。EWC 通过 Fisher 信息矩阵估计源域重要参数，并限制这些参数在目标域微调中的漂移；LWF 通过教师模型软标签约束学生模型，使其在学习目标域时仍保留旧域输出分布；数据回放则在目标训练中混合少量源域样本。相比复杂正则化，知识蒸馏实现简单、计算稳定，适合小样本工业故障诊断场景。

$$L_{KD} = T^2 * KL(\text{softmax}(z_{teacher}/T) \parallel \text{softmax}(z_{student}/T))$$

3 所提方法

3.1 总体框架

本文方法可概括为“源域预训练—教师模型冻结—目标域学生适应—防遗忘约束—双目标评估”的闭环。输入由两个模态构成：三通道时域振动信号 $x_{time} \in \mathbb{R}^{(1024 \times 3)}$ 和由短时傅里叶变换得到的三通道谱图 $x_{spec} \in \mathbb{R}^{(3 \times 128 \times 128)}$ 。双流 CrossViT 分别编码时域与频域信息，并通过跨模态注意力融合形成统一故障表示 z ，最后经分类头输出故障类别概率。

图1 跨功率故障诊断防遗忘迁移学习总体框架

3.2 双流 CrossViT 基础诊断模型

模型包含时域编码器、谱图编码器、跨模态注意力融合模块和分类头。时域编码器捕获局部冲击、周期性调制与多通道传感器关系；谱图编码器捕获故障频带及其能量变化；融合模块利用多头注意力学习两种模态之间的互补关系。其输出为：

$$z_t = E_t(x_{time}), \quad z_f = E_f(x_{spec}), \quad z = \text{Fusion}([z_t, z_f]), \quad p = \text{softmax}(C(z)).$$

源域预训练阶段仅使用 D_s 优化交叉熵损失，得到参数 θ_0 。 θ_0 随后作为教师模型固定，用于目标域适应阶段生成软标签。

3.3 防遗忘目标域适应

目标域适应阶段以 θ_0 初始化学生模型 θ 。若目标域存在少量标注样本，使用目标域交叉熵提升新工况识别能力；同时引入教师模型输出分布和源域回放样本，抑制源域知识遗忘。本文主方法的损失函数为：

$$L = L_{CE}^t + \lambda_r L_{CE}^s + \lambda_{kd} L_{KD}, \quad L_{KD} = T^2 KL(p_{teacher}^T || p_{student}^T).$$

其中 T 为蒸馏温度，控制软标签平滑程度； λ_{kd} 控制蒸馏约束强度； λ_r 控制源域回放比例。实验中 $T=1.8$ 、 $\alpha=0.3$ 取得最佳平衡。EWC、DANN、MMD 和伪标签作为对照策略用于消融分析。

3.4 训练伪代码

```
Algorithm 1 Anti-forgetting cross-power transfer diagnosis
Input: Source data  $D_s$ , target data  $D_t/D_u$ , model  $F_{\theta_0}$ , temperature  $T$ , distillation weight  $\lambda_{kd}$ , replay ratio  $r$ 
Output: Adapted model  $F_{\theta}$  and predictions on target domain
1: Preprocess signals: create time windows and STFT spectrograms
2: Train  $F_{\theta_0}$  on source domain  $D_s$  with cross-entropy loss; save  $\theta_0$ 
3: Freeze a copy  $F_{\theta_0}$  as the teacher model
4: Initialize student model with  $\theta \leftarrow \theta_0$ 
5: for each adaptation epoch do
6:   Sample target mini-batch  $B_t$  and replay source mini-batch  $B_s$ 
7:   Compute target supervised loss  $L_{CE}^t$  when labels are available
8:   Compute replay source loss  $L_{CE}^s$  on  $B_s$ 
9:   Obtain teacher logits  $z_0$  and student logits  $z$  on  $B_s$  or mixed batch
10:  Compute distillation loss  $L_{KD} = T^2 KL(\text{softmax}(z_0/T), \text{softmax}(z/T))$ 
11:  Optionally compute EWC/MMD/DANN/pseudo-label losses for ablation
12:  Update  $\theta$  by minimizing  $L = L_{CE}^t + \lambda_r L_{CE}^s + \lambda_{kd} L_{KD} + \text{optional losses}$ 
13: end for
14: Evaluate Accs, Acct, Balance Score, confusion matrices and attention activation maps
```

4 实验设计

4.1 数据集与任务设置

实验采用跨功率轴承故障诊断任务：源域为 1.0 kW 工况，目标域为 3.0 kW 工况。两个功率域各包含 394 个样本；每个样本同时包含时域振动信号和谱图。故障类别为 10 类，包括正常状态以及不同部位、不同损伤程度的典型轴承故障。

数据域	样本数	Time	Spec	类别数	用途
源域 1.0 kW	394	(1024, 3)	(3, 128, 128)	10	预训练/回放/评估
目域 3.0 kW	394	(1024, 3)	(3, 128, 128)	10	微调/评估

4.2 对比方法与消融配置

对比方法包括：单域训练、跨域无适应、普通微调、冻结微调、EWC、知识蒸馏+LWF、DANN、MMD、伪标签和蒸馏+伪标签组合。消融实验关注三个问题：是否需要防遗忘约束；知识蒸馏温度 T 如何影响平衡；域适应方法是否会牺牲源域保留。

方法组	核心机制	预期作用	潜在风险
普通微调	目标域交叉熵	快速提升目域性能	源域遗忘严重
EWC	Fisher 重要参数约束	限制关键参数漂移	正迁移阻碍适应
KD+LWF	教师软标签+源域回放	兼新域域保留	温度和权重敏感
DANN/MMD	对抗/统计分布对齐	学习域不变特征	可能丢失功率信息
伪标签	高置信目标样本自训练	利用无目域	域差异过大时伪标签噪声高

4.3 评价指标

本文同时报告目标域准确率 Acct 和源域保留率 Accs。为了体现工业部署中的双目标需求，定义 Balance Score：

$$\text{Balance} = \text{Acc_t} + 0.5 * \max(0, \min(\text{Acc_s} - 40, 20)).$$

该指标以目标域准确率为基础，当源域保留率超过 40%时给予线性奖励，奖励上限为 10 分，避免模型过度偏向旧域。

5 结果与分析

5.1 跨域偏移验证

单域基线在 1.0 kW 源域上可达到约 90.0%的平均测试准确率，说明双流 CrossViT 具备充分的单域诊断能力。但源域模型直接迁移到 3.0 kW 目标域时，目标域准确率仅为 10.0%，性能下降约 75 个百分点，证明跨功率域存在显著分布偏移。

5.2 消融实验结果

实验/配置	源域 Accs	目域 Acct	Balance	结论
EXP1 域基	90.0%	-	-	基础模型有效
EXP2 跨域无适应	85.0%	10.0%	-	域偏移显著
EXP3 V3 普通微调	17.5%	77.5%	77.5	目标域高但严重遗忘
EXP3 V3 KD+LWF (T=2)	77.5%	65.0%	75.0	源域保留最佳
EXP3 V4 KD (T=1.8, alpha=0.3)	60.0%	70.0%	80.0	综合最优
DANN/MMD 代表配置	<=12.5%	72.5–75.0%	65.0–75.0	目标域好但遗忘严重
伪标签	70–85%	7.5%	17.5	目标域伪标签失效

结果表明，普通微调能够获得最高目标域准确率之一，但源域准确率下降到 17.5%，不适合需要多工况同时部署的场景。知识蒸馏+LWF 在目标域准确率略低的情况下显著提升源域保留能力；当 T=1.8、alpha=0.3 时，模型在目标域和源域之间取得最佳折中。DANN 和 MMD 能够有效提高目标域性能，但源域保

留率很低，说明强制域不变可能会消除功率相关的诊断信息。伪标签方法在当前任务中表现较差，推测原因是初始目标域置信度不足，错误伪标签被持续放大。

5.3 注意力激活图可视化

为解释模型判断依据，本文建议保存 Transformer 注意力权重，并采用 attention rollout 或 Grad-CAM 将类别响应映射回时域窗口和谱图区域。若模型关注轴承冲击出现的时刻、倍频附近能量带以及故障调制边带，则说明模型学习到与机械故障机理一致的特征；若热区集中在无关噪声区域，则说明模型可能过拟合域特有噪声。

图2 基于注意力的激活图可视化示意

6 讨论

从方法继承关系看，本文并非强调提出全新的基础网络模块，而是在已有迁移学习、域适应和持续学习思想基础上，针对 PHM 跨功率故障诊断场景进行系统组合、比较和评估。其核心价值在于把“目标域准确率”扩展为“目标域迁移 + 源域保留”的双目标问题，并证明知识蒸馏在小样本跨功率适应中比单纯域对齐更稳定。

该结论也提示，在机械故障诊断中，域差异并不总是应被完全消除。功率变化引起的振动能量变化可能同时包含工况信息和故障判别信息，过强的域不变约束可能损害旧域表示。因此，面向实际 PHM 部署时，需要根据任务选择普通微调、域适应或防遗忘迁移：若只关心新工况，可采用 DANN/MMD；若需多工况持续运行，则应优先考虑知识蒸馏和回放策略。

7 结论

本文提出了一种基于知识蒸馏的跨功率故障诊断防遗忘迁移学习框架。该框架以双流 CrossViT 为基础，融合时域信号和谱图信息，通过源域教师模型、目标域学生模型、知识蒸馏和 LWF 回放实现目标域适应与源域知识保留。实验表明， $T=1.8$ 、 $\alpha=0.3$ 的蒸馏配置取得最优 Balance Score，优于普通微调、EWC、DANN、MMD 和伪标签等对照方法。未来工作将进一步扩展到多功率连续迁移、无标签目标域自适应和基于物理机理的可解释可视化。

参考文献（建议在投稿前按 PHM 模板统一格式）

- [1] Y. Zhang and Y. F. Li, Prognostics and health management of Lithium-ion battery using deep learning methods: A review, Renewable and Sustainable Energy Reviews, 2022.
- [2] H. Wang, Y. F. Li, and Y. Zhang, Bioinspired spiking spatiotemporal attention framework for lithium-ion batteries state-of-health estimation, Renewable and Sustainable Energy Reviews, 2023.
- [3] T. Han and Y. F. Li, Out-of-distribution detection-assisted trustworthy machinery fault diagnosis approach with uncertainty-aware deep ensembles, Reliability Engineering & System Safety, 2022.
- [4] T. Han, Y. F. Li, and M. Qian, A hybrid generalization network for intelligent fault diagnosis of rotating machinery under unseen working conditions, IEEE TIM, 2021.

- [5] H. Wang, C. Li, and Y. F. Li, Large-scale visual language model boosted by contrast domain adaptation for intelligent industrial visual monitoring, IEEE TII, 2024.
- [6] X. Yu et al., An adaptive domain adaptation method for rolling bearings fault diagnosis fusing deep convolution and self-attention networks, IEEE TIM, 2023.
- [7] Y. Xiao et al., Novel joint transfer network for unsupervised bearing fault diagnosis from simulation domain to experimental domain, IEEE/ASME TMECH, 2022.
- [8] H. Wang, Y. F. Li, and J. Ren, Machine learning for fault diagnosis of high-speed train traction systems: A review, Frontiers of Engineering Management, 2024.