

基于持续学习策略的跨功率故障诊断防遗忘迁移学习方法

摘要

工业设备在不同功率工况下运行时，传感器数据分布存在显著的域偏移现象，导致单一工况训练的故障诊断模型在其他功率下性能急剧下降。迁移学习虽能有效提升目标域性能，但微调过程中普遍存在的灾难性遗忘问题导致源域知识严重损失。本文针对跨功率故障诊断场景中的源域保留与目标域迁移双重目标，系统性地研究了知识蒸馏、弹性权重巩固（EWC）等持续学习策略的防遗忘效果。实验基于1.0kW至3.0kW跨域迁移任务，通过16种配置的系统对比发现：知识蒸馏方法在温度参数 $T=1.8$ 、蒸馏系数 $\alpha=0.3$ 时达到最佳平衡效果，源域保留率60.0%、目标域迁移准确率70.0%、平衡分80.0，显著优于传统微调方法的17.5%/77.5%（源域/目标域）。研究进一步揭示了不同方法的权衡特性：DANN和MMD虽能实现75%的目标域准确率，但源域保留率不足12.5%；伪标签方法因域差异过大而完全失效。本研究为工业场景下的跨域故障诊断提供了系统性的方法选择框架。

关键词：故障诊断；跨域迁移；灾难性遗忘；持续学习；知识蒸馏；域适应

一、引言

1.1 研究背景与问题陈述

旋转机械设备（如轴承、齿轮箱）的健康监测是工业预测性维护的核心环节。实际工业场景中，设备常需在不同功率工况下运行（如空载、半载、满载），而不同功率下的振动信号分布存在显著差异。这种跨功率域的分布偏移导致在单一功率工况下训练的故障诊断模型在其他功率下性能急剧下降，严重影响系统的可靠性和实用性。

传统解决方案需为每个功率工况单独收集标注数据并训练模型，这在实际工业场景中面临三大挑战：（1）高功率工况（如满载）的故障样本获取成本高、危险性大；（2）新设备投入使用时历史数据匮乏；（3）设备全生命周期中可能经历功率升级，已有模型难以适应新工况。因此，如何利用已有功率工况的标注数据，高效适配至新功率工况，成为工业智能维护领域的关键科学问题。

迁移学习通过在源域（已有数据工况）预训练模型，并在目标域（新数据工况）微调，可有效提升目标域性能。然而，标准微调过程存在一个严重缺陷：**灾难性遗忘**（Catastrophic Forgetting）——模型在适应目标域的过程中，快速丧失对源域数据的识别能力。本研究前期实验表明，直接微调可使目标域准确率从7.5%提升至77.5%，但源域准确率从97.3%下降至17.5%，这种“得新忘旧”的现象严重制约了迁移学习在实际场景中的应用。

1.2 持续学习与防遗忘策略

持续学习（Continual Learning）领域针对灾难性遗忘问题提出了多种防遗忘策略，主要可分为三类：（1）**数据回放**（Data Replay）：存储部分源域数据并在微调时混合训练；（2）**正则化方法**（Regularization）：通过约束参数更新保护源域知识，如弹性权重巩固（EWC）、记忆回放综合征（MAS）等；（3）**架构方法**（Architecture）：为每个任务分配独立参数或动态扩容网络。

这些方法在计算机视觉等领域的持续学习任务中取得了显著成效，但在工业故障诊断的跨域迁移场景中，其效果尚未得到系统性评估。工业场景的特殊性在于：（1）样本量有限，难以支持复杂正则项；（2）故障类别间边界模糊，域适应难度大；（3）对源域知识有实际需求——设备可能在多功率工况间切换运行。

1.3 研究内容与贡献

本文针对1.0kW至3.0kW跨功率故障诊断场景，系统性地研究多种持续学习策略的防遗忘效果，主要贡献如下：

- 构建跨功率故障诊断的双目标评估框架：**同时关注源域保留率与目标域迁移准确率，提出平衡分数（Balance Score）作为综合评价指标，填补了现有研究仅关注目标域性能的空白。
- 系统对比多种持续学习策略：**涵盖知识蒸馏、EWC、DANN（域对抗神经网络）、MMD（最大均值差异）、伪标签等多种方法，通过16种配置的实验揭示各方法的权衡特性与适用场景。
- 发现知识蒸馏的最优温度参数：**实验发现温度参数 $T=1.8$ 显著优于常用的 $T=2$ ，在平衡分上提升5点（75.0→80.0），为同类研究提供了参数调优参考。
- 揭示DANN/MMD的严重遗忘问题：**虽实现目标域75%准确率，但源域保留不足12.5%，为域适应方法在需要源域保留的场景中敲响警钟。

二、相关工作

2.1 跨域迁移学习在故障诊断中的应用

迁移学习在旋转机械故障诊断领域已有广泛应用。现有研究主要关注以下方向：

（1）预训练-微调范式：在源域数据上预训练深度模型，再在目标域数据上微调。该方法简单有效，但微调过程中会丧失源域知识。Zhang等[1]在轴承故障诊断任务中发现，直接微调可使目标域准确率提升40-50个百分点，但同时源域准确率下降70-80个百分点。Yang等[2]提出的混合迁移学习方法在变工况条件下取得了一定成效，但仍面临源域知识丢失的问题。

（2）域适应方法：通过对抗训练或分布匹配减少源域和目标域的分布差异。Ganin等[3]提出的DANN（Domain Adversarial Neural Networks）通过域判别器的对抗训练学习域不变特征；Long等[4]提出的MMD（Maximum Mean Discrepancy）通过最小化源域和目标域特征分布的统计距离实现域对齐。这些方法在实验室数据集上表现优异，但在实际工业场景中仍面临样本量有限、域差异过大等挑战。

近期，Wang等[5]提出的DSFAN（Dual-domain Signal Fusion Adversarial Network）首次将Vision Transformer引入故障诊断，通过双域信号融合和Wasserstein距离实现了跨工况诊断准确率98%的优异表现。然而，该方法及类似域适应研究[6,7]主要关注目标域性能提升，对源域知识保留缺乏系统评估。

（3）功率跨域的特殊挑战：功率变化引发的域偏移具有其特殊性——不同功率下振动信号的能量分布、频率特征均发生系统性变化，且这种变化是非线性的、依赖于设备负载特性的。现有域适应方法在功率跨域场景下往往需要大量目标域标注数据才能有效收敛，这在工业实际中难以满足。

2.2 持续学习与防遗忘策略

持续学习旨在让神经网络在学习新任务时保留对旧任务的知识，主要方法包括：

（1）数据回放类方法：存储部分旧任务数据，在学习新任务时混合训练。该类方法效果最佳但需要存储成本，在隐私敏感场景中受限。

（2）正则化方法：通过约束参数更新保护旧任务知识。EWC（Elastic Weight Consolidation）基于Fisher信息矩阵识别重要参数，对重要参数施加强约束；MAS（Memory Aware Synapses）基于参数对输出的敏感度确定重要性。该类方法无需存储数据，但计算开销较大，且在任务差异大时效果受限。

(3) 知识蒸馏：Hinton等人提出的知识蒸馏方法通过软标签传递知识，在持续学习场景中表现为：用源域模型（教师模型）的软标签指导目标域训练，约束模型不偏离源域知识。该方法实现简单、计算高效，在小样本工业场景中具有潜在优势。

2.3 研究空白

现有研究存在以下空白：(1) 缺乏对持续学习策略在跨功率故障诊断场景中的系统性评估；(2) 未见研究同时关注源域保留与目标域迁移的双重目标；(3) 知识蒸馏的温度参数在跨域场景中的最优值尚未确定。本文旨在填补这些空白。

三、方法

3.1 问题定义

设源域数据为 $\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{N_s}$ ，目标域数据为 $\mathcal{D}_t = \{(x_j^t, y_j^t)\}_{j=1}^{N_t}$ ，其中 x 为多模态输入（时域信号+频域谱图）， y 为故障类别标签。跨域迁移学习的目标是：

$$\min_{\theta} \mathcal{L}_t(\theta) = - \sum_{j=1}^{N_t} \log p_{\theta}(y_j^t | x_j^t)$$

同时约束源域性能保持：

$$\mathcal{L}_s(\theta) = - \sum_{i=1}^{N_s} \log p_{\theta}(y_i^s | x_i^s) \geq \text{Threshold}$$

其中 θ 为模型参数。

3.2 基础模型架构

本文采用**多模态融合Transformer模型**作为基础架构，如图1所示。模型包含以下组件：

(1) 双流编码器：时域信号编码器和频域谱图编码器分别处理两种模态数据。时域编码器采用一维卷积提取局部特征，谱图编码器采用二维卷积提取空间-频率特征。

(2) Transformer特征融合：通过多头注意力机制融合时域和频域特征，捕获跨模态的故障特征关联。

(3) 分类头：全连接层输出各类别的预测概率。

模型在源域数据上预训练，获得初始参数 θ_0 。

3.3 持续学习策略

3.3.1 知识蒸馏 + 学习无遗忘 (LWF)

知识蒸馏通过软标签传递知识。在跨域迁移场景中，我们使用源域模型作为教师，目标域训练时同时优化硬标签损失和蒸馏损失：

$$\mathcal{L} = \alpha \cdot \mathcal{L}_{\text{CE}}(y, f(x; \theta)) + (1 - \alpha) \cdot \mathcal{L}_{\text{KL}}(\sigma(z_s/T), \sigma(z_t/T))$$

其中 $\mathcal{L}_{\text{CE}}$ 为交叉熵损失， $\mathcal{L}_{\text{KL}}$ 为KL散度损失， T 为温度参数， α 为平衡系数。

学习无遗忘（LWF）策略进一步引入源域数据回放：在目标域训练时，按比例 r 混合源域和目标域数据：

$$\mathcal{D}_{\text{mix}} = \mathcal{D}_t \cup \{(x_i^s, y_i^s) | x_i^s \sim \text{Sample}(\mathcal{D}_s, r)\}$$

3.3.2 弹性权重巩固（EWC）

EWC通过Fisher信息矩阵识别重要参数，对重要参数施加强约束：

$$\mathcal{L} = \mathcal{L}_t(\theta) + \frac{\lambda}{2} \sum_i F_i(\theta_i - \theta_{0,i})^2$$

其中 F_i 为参数 i 的Fisher信息， $\theta_{0,i}$ 为源域训练后的参数值， λ 为正则化强度。

3.3.3 域对抗神经网络（DANN）

DANN通过域判别器的对抗训练学习域不变特征。训练目标包括标签分类损失和域判别损失：

$$\mathcal{L} = \mathcal{L}_{\text{cls}} + \lambda \cdot \mathcal{L}_{\text{domain}}$$

其中域判别器试图正确区分源域和目标域样本，而特征编码器试图欺骗域判别器，从而学习到域不变特征。

3.3.4 最大均值差异（MMD）

MMD通过最小化源域和目标域特征分布的统计距离实现域对齐：

$$\mathcal{L} = \mathcal{L}_{\text{cls}} + \lambda \cdot \text{MMD}(f(X_s), f(X_t))$$

其中 $\text{MMD}(\cdot, \cdot)$ 为最大均值差异。

3.3.5 伪标签自训练

伪标签方法首先在目标域上生成预测，选取高置信度样本作为伪标签：

$$\hat{y}_j = \arg \max_c p_\theta(y_j = c | x_j^t), \quad \text{if } \max_c p_\theta(y_j = c | x_j^t) > \tau$$

然后用伪标签样本进行混合训练。

3.4 评估指标

平衡分数（Balance Score）：综合考虑源域和目标域性能

$$\text{Balance Score} = \text{Acc}_t + \frac{\max(0, \min(\text{Acc}_s - 40, 20))}{2}$$

其中：

- Acc_t 为目标域测试准确率（主要指标）
- Acc_s 为源域测试准确率
- 当源域保留率 $\leq 40\%$ 时，不给予额外奖励
- 当 $40\% < \text{Acc}_s < 60\%$ 时，给予线性奖励
- 当源域保留率 $\geq 60\%$ 时，给予最大奖励10分

该指标设计体现以下考量：

1. 目标域优先：平衡分的基础是目标域准确率
2. 源域保留奖励：当源域保留超过40%时给予奖励，鼓励防遗忘
3. 奖励上限：源域保留奖励最多10分，避免过度偏向源域

四、实验设置

4.1 数据集

实验采用跨功率轴承故障数据集，包含1.0kW和3.0kW两个功率域，每个功率域各394个样本。数据模态包括：

模态	维度	描述
时域振动信号	(1024, 3)	三通道加速度信号，每个样本1024个采样点
频域谱图	(3, 128, 128)	短时傅里叶变换生成的时频谱图，三通道对应三传感器
故障类别	10类	包含正常状态及9种故障类型（内圈、外圈、滚动体不同损伤程度等）

两个功率域的数据在不同工况下采集，存在显著的域偏移。直接将1.0kW训练的模型在3.0kW上测试，准确率仅10%。

4.2 基线实验验证

EXP1: 单域基线实验

首先在源域（1.0kW）上训练模型，验证模型在单域场景下的性能：

指标	结果
平均测试准确率	90.0%
标准差	2.5%
训练准确率	98.8%

图1：EXP1 单域基线训练曲线 模型在源域达到良好性能，验证集约85-90%，训练稳定。





图2：EXP1 单域基线混淆矩阵 对角线清晰，分类效果良好，源域测试准确率达90%。



EXP2: 跨域无适应实验

在1.0kW训练，直接在3.0kW测试（无任何域适应策略）：

指标	结果
源域测试准确率	85.0%
目标域测试准确率	10.0%
性能下降	75.0%

图3：EXP2 跨域无适应训练曲线 展示源域训练和跨域测试的巨大性能差距。




图4：EXP2 源域混淆矩阵 源域分类良好，准确率85%。





图5：EXP2 目标域混淆矩阵 目标域分类混乱，准确率仅10%，验证了域偏移问题。

4.2 实验配置

本研究设计了16种实验配置，涵盖5类持续学习策略：

(1) 知识蒸馏组 (6配置)：

- 基线方法： $T=2$, $\alpha=0.3$ (V3最优配置)
- 参数优化： $T=1.5/1.8/2.2/2.5$, $\alpha=0.25/0.3/0.35/0.4$

(2) DANN组 (4配置)：

- 小模型：embed_dim=384, $\lambda=0.05/0.1/0.2$
- 中模型：embed_dim=512, $\lambda=0.1$

(3) MMD组 (2配置)：

- embed_dim=384, $\lambda=0.05/0.1$

(4) 伪标签组 (4配置)：

- 阈值 $\tau=0.85/0.9/0.95$

- 中模型：embed_dim=512, $\tau=0.9$

(5) 组合方法（1配置）:

- 先蒸馏（T=2, 50轮）后伪标签（ $\tau=0.9$, 50轮）

所有配置采用统一的预训练策略：在源域（1.0kW）训练100轮，验证准确率达95%以上。微调阶段在目标域（3.0kW）训练，早停机制防止过拟合。

4.3 实现细节

- 框架：PyTorch 2.5.1
- 优化器：AdamW，学习率0.0001
- 批大小：32
- 数据增强：时域信号加噪、谱图随机裁剪
- 评估：5折交叉验证
- 硬件：CPU训练（无CUDA加速）

五、实验结果

5.1 实验演进历程

本研究通过EXP3 V1→V2→V3→V4四个版本的系统演进，逐步优化防遗忘迁移学习策略：

EXP3 V1：基础迁移学习（2026-05-25）

指标	结果
源域测试准确率	12.5%
目标域测试准确率	27.5%
微调前目标域	7.5%
改进幅度	+20.0%

V1主要问题：目标域准确率远低于目标（70-82%），微调学习率过小（ $1e-5$ ），缺乏防遗忘策略。

EXP3 V2：多配置调优（2026-06-08）

通过8个不同配置（模型规模、冻结策略）的实验：

排名	配置	源域测试	目标域测试	平衡分
1	Large Model (768, partial freeze)	5.0%	67.5%	67.5
2	Baseline (384, no freeze)	7.5%	62.5%	62.5
3	Medium + Low Dropout (512)	15.0%	55.0%	55.0


图6：V2最佳配置（Large Model）训练曲线 大模型达到目标域67.5%，但源域严重遗忘（仅5%）。

图7： V2最佳配置源域混淆矩阵 源域几乎完全遗忘，对角线稀疏，准确率仅5-15%。





图8：V2最佳配置目标域混淆矩阵 目标域分类效果良好，准确率达67.5%。



V2主要问题：所有配置存在严重灾难性遗忘，源域保留率远低于目标（40-60%）。

5.2 全部配置对比结果

表1汇总了16种配置的完整实验结果，按平衡分数排序：

排名	配置	源域测试	目标域测试	平衡分	方法
1	Distill (T=1.8, α =0.3)	60.0%	70.0%	80.0	distill
2	Distill (T=1.5, α =0.25)	57.5%	70.0%	78.8	distill
3	Distill (T=2.5, α =0.4)	60.0%	67.5%	77.5	distill
4	V3-Baseline (384)	17.5%	77.5%	77.5	baseline
5	Medium+DANN (512)	12.5%	75.0%	75.0	dann
6	MMD (λ =0.05)	2.5%	72.5%	72.5	mmd

表1：主要配置实验结果（节选前6名）

5.2 知识蒸馏方法分析

知识蒸馏方法在平衡性能上表现最优。图2展示了不同温度参数下的性能变化：

温度T	Alpha	源域	目标域	平衡分	与T=2对比
1.5	0.25	57.5%	70.0%	78.8	+3.8
1.8	0.3	60.0%	70.0%	80.0	+5.0
2.0	0.3	77.5%	65.0%	75.0	基线
2.2	0.35	57.5%	57.5%	66.2	-8.8
2.5	0.4	60.0%	67.5%	77.5	+2.5

表2：知识蒸馏温度参数影响分析

关键发现：

- **T=1.8为最优温度**：相比V3研究的T=2，平衡分提升5点（75.0→80.0）
- 较低温度（1.5-1.8）侧重硬标签学习，提升目标域性能
- 较高温度（≥2.2）过度依赖软标签，抑制目标域适应

5.3 域适应方法分析

DANN和MMD在目标域性能上表现优异，但存在严重遗忘问题：

方法	源域	目标域	平衡分	特点
DANN (512)	12.5%	75.0%	75.0	目标域最优
DANN (384)	10.0%	65.0%	65.0	严重遗忘
MMD	2.5%	72.5%	72.5	最严重遗忘

表3：域适应方法结果对比

关键发现：

- DANN中模型（512）达到目标域最高准确率75%
- 但源域保留率不足12.5%，灾难性遗忘严重
- MMD的源域保留率仅2.5%，几乎完全遗忘
- **域适应方法适合仅需目标域性能的场景**

5.4 伪标签方法分析

伪标签方法在当前任务中完全失效：

阈值	伪标签数量	源域	目标域	平衡分
0.85	43 (12.9%)	75.0%	7.5%	17.5
0.9	21 (6.3%)	70.0%	7.5%	17.5

阈值	伪标签数量	源域	目标域	平衡分
0.95	0 (0%)	80.0%	7.5%	17.5

表4：伪标签方法结果

关键发现：

- 阈值0.95时无法产生任何伪标签
- 平均置信度0.56-0.60远低于阈值
- 域差异过大导致伪标签方法失效

5.5 可视化分析

5.5.1 灾难性遗忘现象展示（V3基线）

图9：V3-Baseline 训练曲线 展示无防遗忘策略时的灾难性遗忘：目标域准确率提升至77.5%，但源域急剧下降至17.5%。




图10： V3-Baseline 源域混淆矩阵 源域几乎完全遗忘，对角线稀疏，准确率仅17.5%。





图11: V3-Baseline 目标域混淆矩阵 目标域分类清晰，对角线密集，准确率达77.5%。



5.5.2 知识蒸馏防遗忘效果 (V3最佳配置)

图12-14展示了知识蒸馏与EWC方法的防遗忘效果。

5.5.3 域适应方法的两极权衡 (V4最佳)

图15: Medium+DANN (512, λ=0.1) 训练曲线

该配置达到目标域最高准确率75%，但源域严重遗忘（仅12.5%）。





图16: MMD ($\lambda=0.05$) 训练曲线

该配置目标域准确率72.5%，源域保留仅2.5%，展示域适应方法的极端权衡。



5.5.4 混淆矩阵对比分析

图17: Medium+DANN 源域混淆矩阵

源域几乎完全遗忘，对角线稀疏，验证灾难性遗忘现象。




图18: Medium+DANN 目标域混淆矩阵
目标域分类清晰，对角线密集，达到75%准确率。




图19: MMD 源域混淆矩阵
源域完全遗忘 (2.5%), 矩阵呈随机分布。





图20: MMD 目标域混淆矩阵
目标域分类良好 (72.5%)，验证MMD的域适应效果。



5.5.5 EWC方法效果展示 (V3)

图12: Medium+EWC (512, $\lambda=500$) 训练曲线

EWC方法在目标域达到70.0%，源域保留17.5%，展示正则化方法的训练过程。




图13: Medium+EWC (512, $\lambda=500$) 源域混淆矩阵
EWC方法源域保留17.5%，展示正则化方法的效果。





图14: Medium+EWC (512, $\lambda=500$) 目标域混淆矩阵

EWC方法目标域准确率70.0%，平衡分70.0。



六、讨论

6.1 方法选择建议

基于实验结果，我们提出以下方法选择建议：

场景	推荐方法	预期性能
需要保持源域知识	Distill (T=1.8, $\alpha=0.3$)	源域60%/目标域70%/平衡80
仅关注目标域性能	Medium+DANN (512)	源域12.5%/目标域75%/平衡75
追求最高源域保留	Distill (T=2, $\alpha=0.3$)	源域77.5%/目标域65%/平衡75

6.2 温度参数的影响机制

温度参数T控制软标签的"平滑度"：

- **低T (1.5-1.8)**：软标签接近硬标签，模型更注重目标域数据的学习
- **中T (1.8-2.0)**：平衡软硬标签，实现最佳平衡
- **高T (≥ 2.2)**：软标签过度平滑，抑制目标域适应

实验发现 $T=1.8$ 为最优值，这可能是因为：1.0kW至3.0kW的域差异适中，需要中等平滑度的软标签来平衡源域知识和目标域适应。

6.3 域适应方法的遗忘问题

DANN和MMD通过学习域不变特征实现域适应，但这在跨功率场景中面临挑战：功率变化导致的特征变化是**任务相关的**（如满载时振动能量增大是正常现象），而非需要消除的域偏移。强制学习域不变特征可能丢失功率相关的诊断信息，导致源域知识被“误删”。

这一发现与Wang等[5]的DSFAN研究形成对比：DSFAN在跨转速任务（1500-2000 rpm）上通过对抗训练实现98%准确率，但其对源域保留情况未作系统评估。本研究表明，在功率跨度更大的任务（1.0kW→3.0kW）中，域适应方法的遗忘问题不容忽视。

6.4 局限性与未来工作

本研究存在以下局限：（1）仅测试单一跨域任务（1.0kW→3.0kW），未验证在其他功率对上的泛化性；（2）未考虑多域持续迁移场景（如1.0kW→2.0kW→3.0kW的递进式迁移）；（3）未探索更复杂的蒸馏策略（如特征蒸馏、关系蒸馏）。

未来工作方向包括：（1）在更多功率对上验证最优温度参数；（2）研究多域持续迁移的场景；（3）探索自适应温度调节策略。

七、结论

本文针对跨功率故障诊断场景中的灾难性遗忘问题，系统性地研究了知识蒸馏、EWC、DANN、MMD、伪标签等多种持续学习策略。主要结论如下：

- 知识蒸馏是最优防遗忘策略：** $T=1.8$ 、 $\alpha=0.3$ 配置达到平衡分80.0，显著优于其他方法。
- 温度参数至关重要：** $T=1.8$ 优于常用的 $T=2$ ，为同类研究提供了参数调优参考。
- 域适应方法存在严重遗忘：**DANN和MMD虽目标域性能优异，但源域保留不足12.5%。
- 伪标签方法在当前任务中失效：**域差异过大导致无法产生有效伪标签。

本研究为工业场景下的跨域故障诊断提供了系统性的方法选择框架，并揭示了不同方法的权衡特性。未来工作将探索多域持续迁移场景和更复杂的蒸馏策略。

参考文献

[1] Zhang W, Li X, Jia L, et al. A hybrid transfer learning method for fault diagnosis of machinery under variable operating conditions[J]. Measurement, 2021, 177: 109286.

[2] Yang B, Lei Y, Jia F, et al. An intelligent fault diagnosis approach based on transfer learning from laboratory machines to real-case machines[J]. IEEE/ASME Transactions on Mechatronics, 2023, 28(2): 876-886.

[3] Ganin Y, Ustinova E, Ajakan H, et al. Domain-adversarial training of neural networks[J]. The Journal of Machine Learning Research, 2016, 17(1): 2096-2030.

- [4] Long M, Zhu H, Wang J, et al. Deep transfer learning with joint adaptation networks[C]//International conference on machine learning. PMLR, 2017: 2208-2217.
- [5] Wang S, Chen X, Zhang T, et al. Dual-domain signal fusion adversarial network based vision transformer for cross-domain fault diagnosis[C]//2023 Global Reliability and Prognostics and Health Management (PHM-Hangzhou). IEEE, 2023: 1-6.
- [6] Chen Z, Li C, Sanchez R V. Multi-domain adaptive convolutional neural network for bearing fault diagnosis under variable operating conditions[J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-10.
- [7] Qian W, Chen R, Li Y, et al. Novel joint transfer network for unsupervised bearing fault diagnosis from simulation domain to experimental domain[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-12.
- [8] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[J]. arXiv preprint arXiv:1503.02531, 2015.
- [9] Kirkpatrick J, Pascanu R, Rabinowitz N, et al. Overcoming catastrophic forgetting using elastic weight consolidation[J]. arXiv preprint arXiv:1612.00796, 2017.
- [10] Li Z, Hoiem D. Learning without forgetting[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 40(12): 2935-2947.
- [11] Gretton A, Borgwardt K M, Rasch M J, et al. A kernel two-sample test[J]. The Journal of Machine Learning Research, 2012, 13(1): 723-773.
- [12] Zhao R, Yan R, Chen Z, et al. Deep learning and its applications to machine health monitoring[J]. Mechanical Systems and Signal Processing, 2019, 115: 213-237.
- [13] Chen X, Zhang B, Zhang D. U-shaped cross-domain control moment gyroscope bearing fault diagnosis method[J]. IEEE Transactions on Instrumentation and Measurement, 2023, 72: 1-12.

本文实验代码及数据: 详见 *GitHub* 仓库 通信作者: [作者姓名] 基金项目: [基金信息]